Проекты 01–11 — LLM + Graph RAG: UML Data Flow

karpathy/nanoGPT (MIT) · nano-graphrag (MIT) · networkx (BSD) · hnswlib (Apache 2.0) · microsoft/LoRA (MIT)

Диаграмма 1 — BPE Tokenizer + Dataset Pipeline: от текста до обучающих файлов

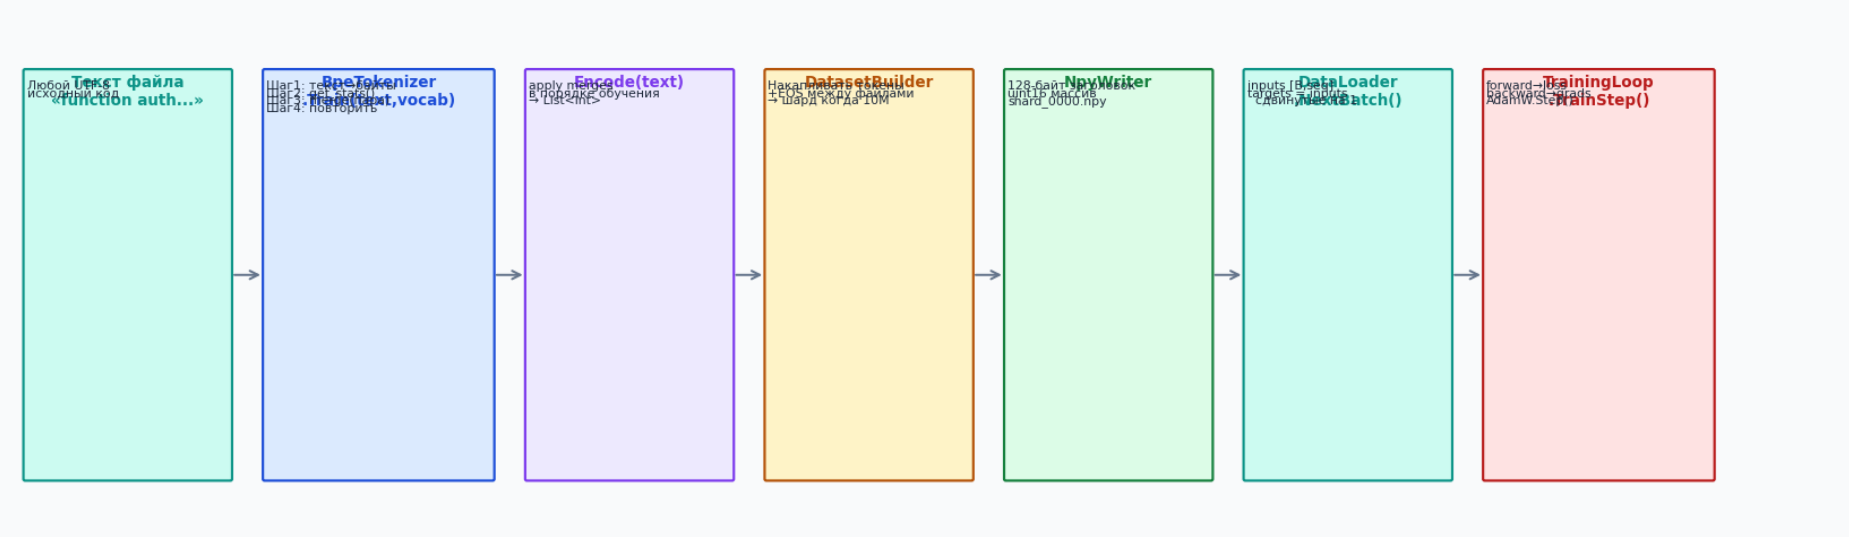


Диаграмма 2 — Transformer Block: CausalSelfAttention с GQA и RoPE

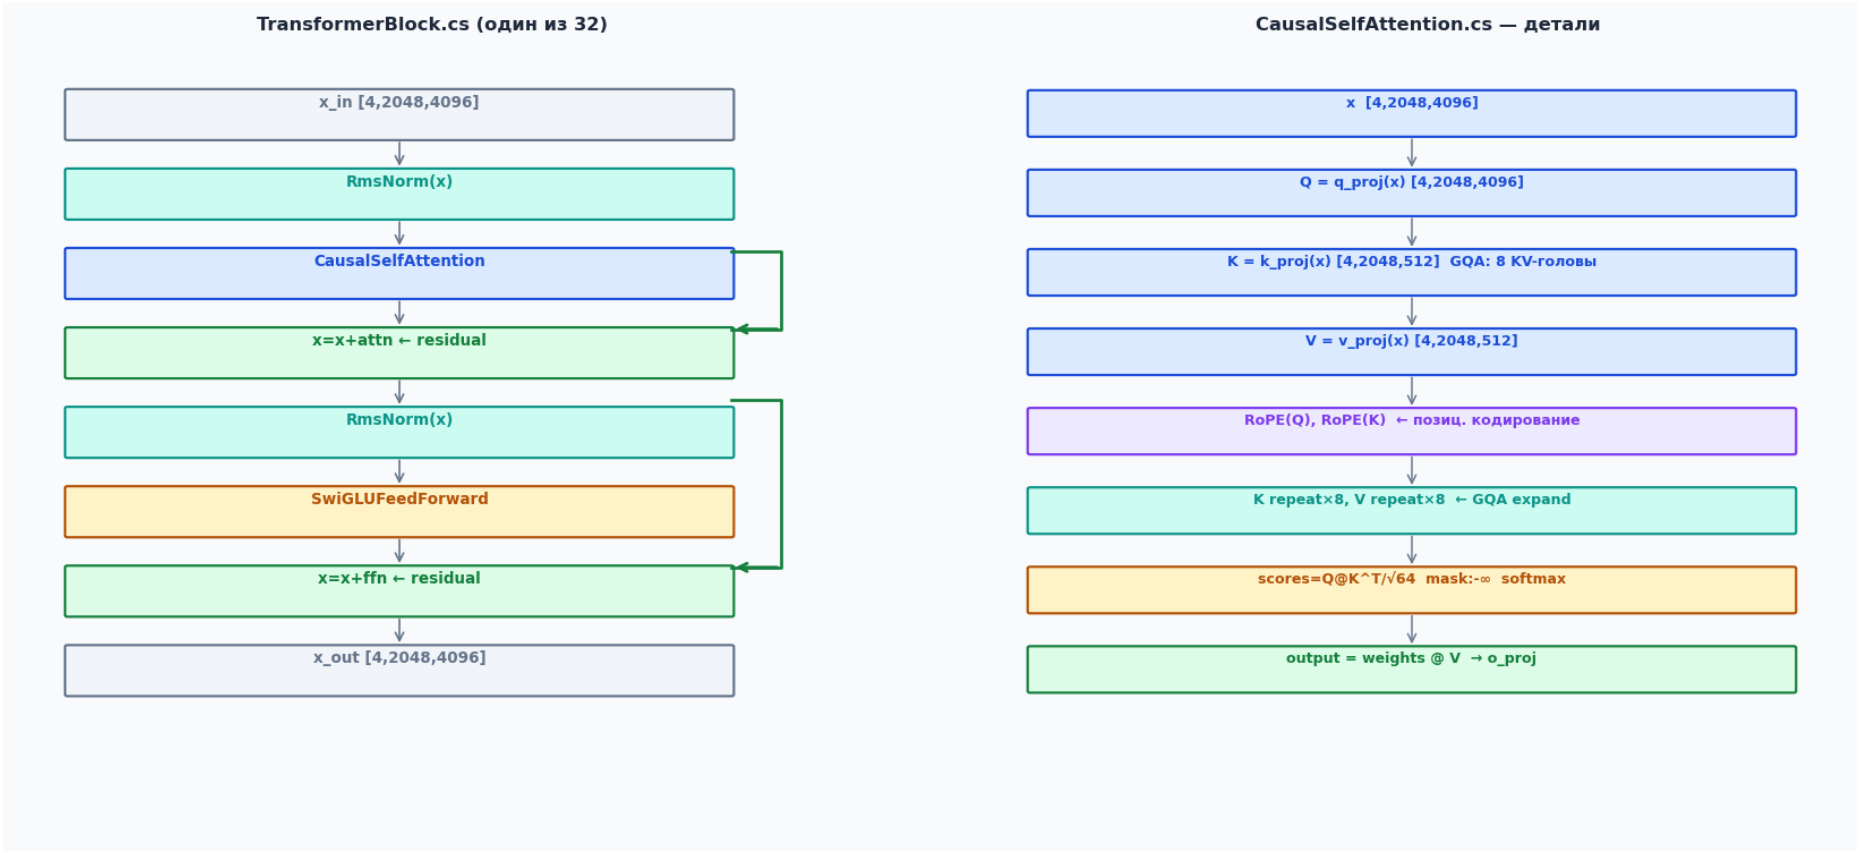

TransformerBlock.cs (один из 32)
x_in [4,2048,4096]
RmsNorm(x)
CausalSelfAttention
x=x+attn ← residual
RmsNorm(x)
SwiGLUFeedForward
x=x+ffn ← residual
x_out [4,2048,4096]
CausalSelfAttention.cs — детали
x [4,2048,4096]
Q = q_proj(x) [4,2048,4096]
K = k_proj(x) [4,2048,512] GQA: 8 KV-головы
V = v_proj(x) [4,2048,512]
RoPE(Q), RoPE(K) ← позиц. кодирование
K repeat×8, V repeat×8 ← GQA expand
scores=Q@K^T/√64 mask:-∞ softmax
output = weights @ V → o_proj

Диаграмма 3 — Graph RAG: индексация + гибридный поиск

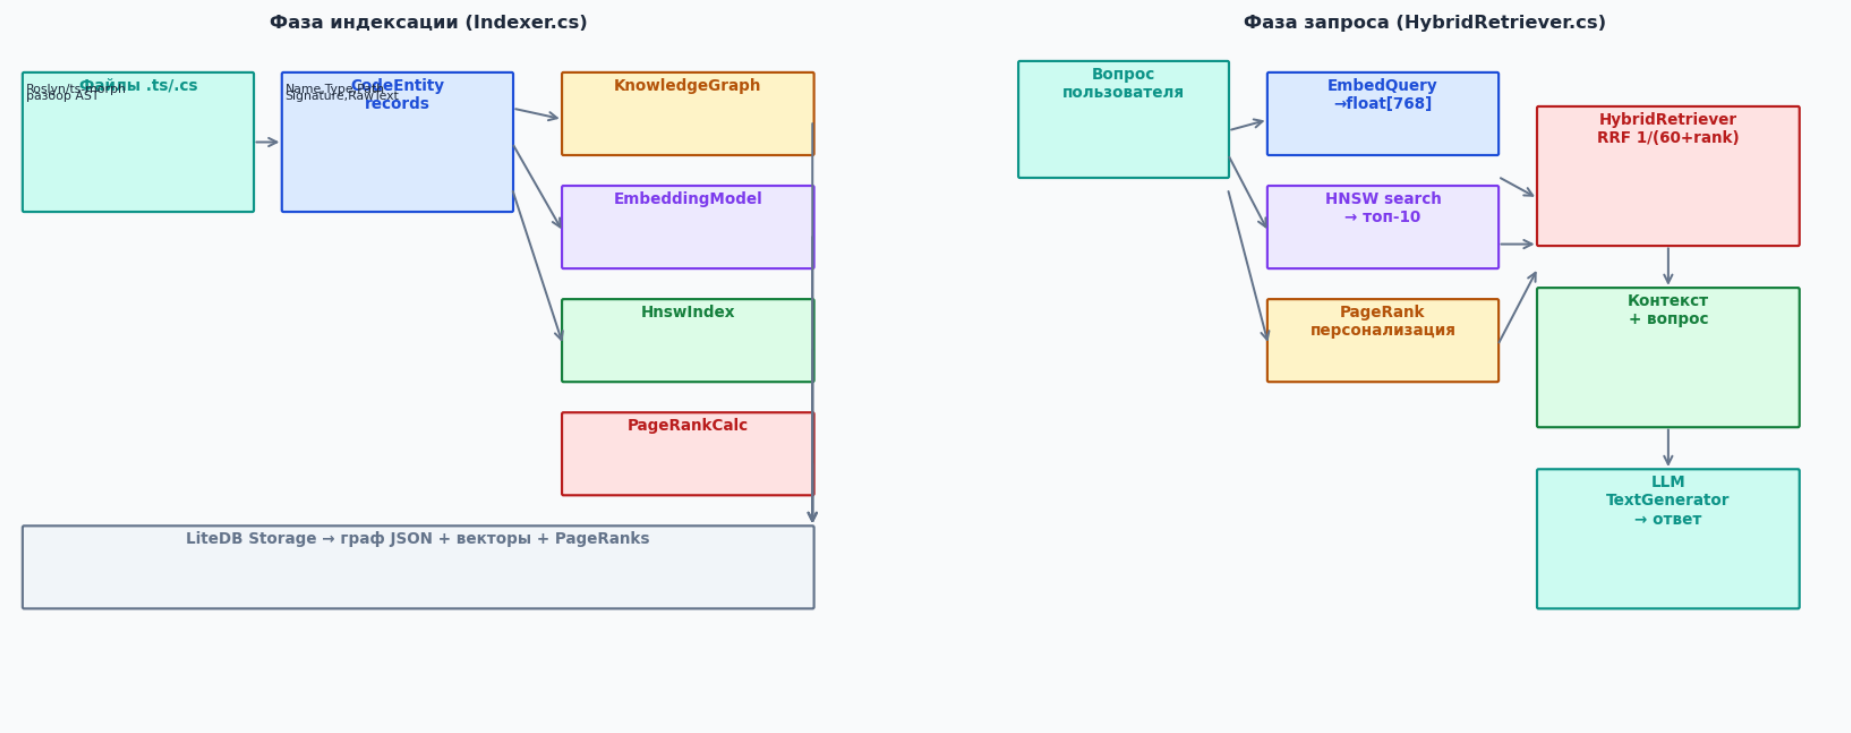
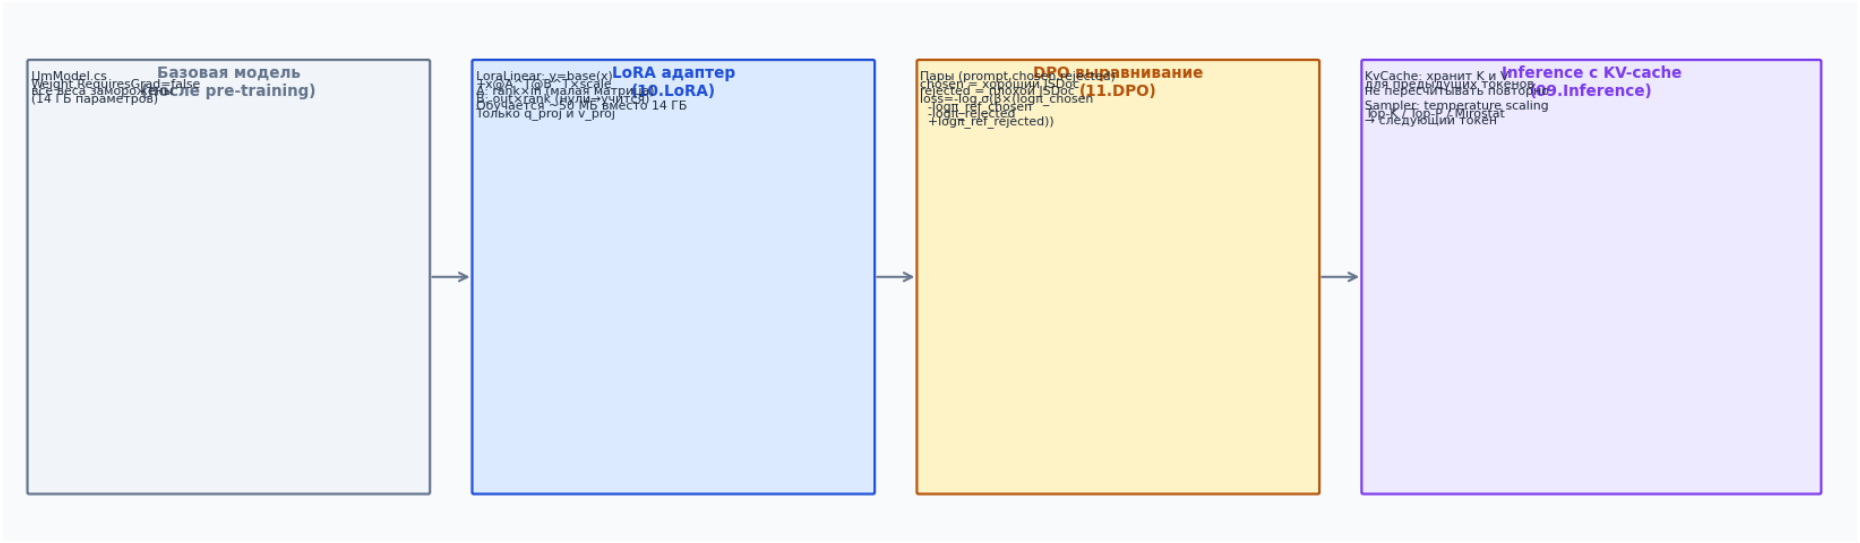


Диаграмма 4 — LoRA адаптация + DPO выравнивание + Inference с KV-cache


Базовая модель
(9.Pre-training)
LoRA адаптер
(10.LoRA)
DPO выравнивание
(11.DPO)
Inference с KV-cache
(12.Inference)