Семантическая токенизация — Потоки данных (подпроекты 28–32)

Что именно передаётся на каждом шаге — без кода, простым языком

Схема 1 — Пять подходов: чем отличаются и что на выходе

Обычный токенизатор (BPE): «бежать», «бежит», «бежал» → один токен (общий корень). Семантические подходы: «бежать», «спасаться», «скрываться» → одна группа (одно намерение). Как design patterns в программировании: Factory, Builder, Prototype — разные, но одна семья.

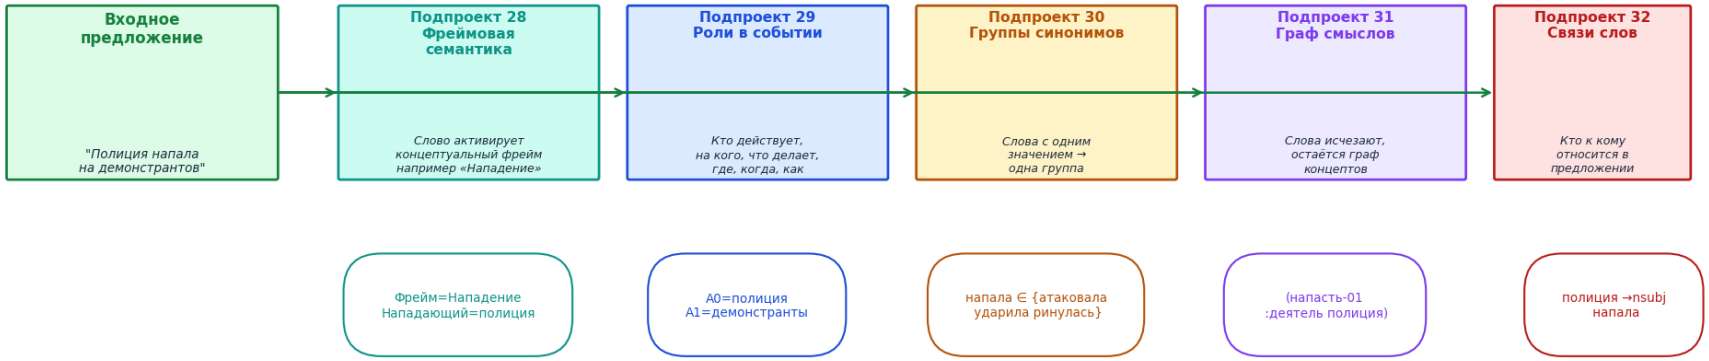


Схема 2 — Подпроект 28: Фреймовая семантика (FrameNet)

Аналогия из архитектуры ПО: Design Patterns. "Factory", "Builder", "AbstractFactory" — разные паттерны, но одна семья («создание объектов»). FrameNet делает то же: «напасть», «атаковать», «ударить» → одна семья («Нападение»). Фрейм = паттерн с ролями (кто нападает, на кого, чем).


Поток данных через фреймовый анализ
Вход: предложение «Взломщик вскрыл сейф»
Шаг 1 → Каждое слово проверяется в словаре фреймов
Словарь: {напасть: [Нападение], купить: [Покупка], вскрыть: [Кража]}
Каждому слову → список фреймов которые оно может активировать
Шаг 2 → Голосование: какой фрейм набрал больше баллов
Слово «вскрыл» → Кража (+1), Разрушение (+1)
Слово «сейф» → Кража (+1), Хранение (+1)
Фрейм «Кража» победил с 2 голосами
Шаг 3 → Присвоение ролей по позиции в предложении
Слово до триггера → роль «Деятель» (кто выполняет)
Слово после триггера → роль «Объект» (что получает действие)
Шаг 4 → Сохранение аннотации
Фрейм=Кража, Триггер=вскрыл
Деятель=Взломщик, Объект=сейф
Шаг 5 → Запись события и сохранение в хранилище
StandardEvent {тип=«аннотация_завершена», фрейм=Кража, id=опер.}
ISemanticStorage.Save(предложение_id, аннотация)

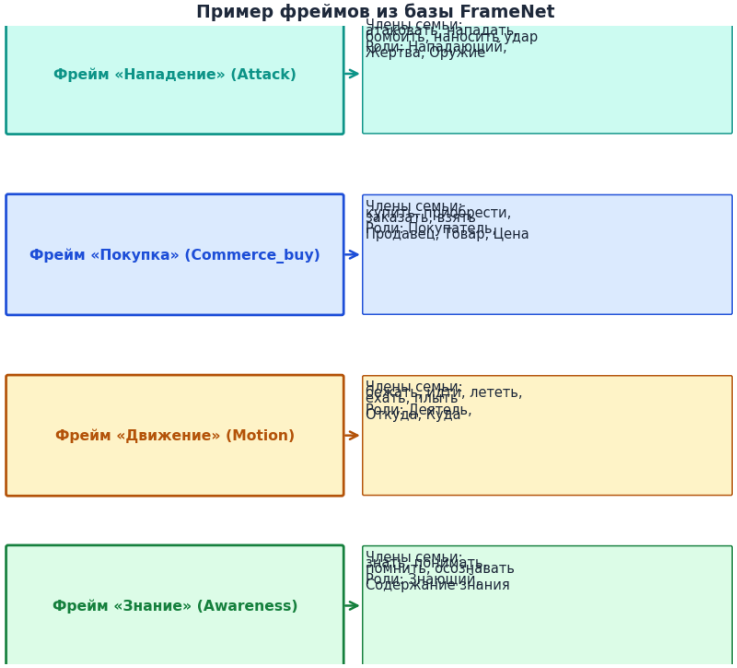

Пример фреймов из базы FrameNet
Фрейм «Нападение» (Attack)
Члены семьи:
Роли: Нападающий,
Жертва, Оружие
Фрейм «Покупка» (Commerce_buy)
Члены семьи:
Роли: Покупатель
Продавец, Товар, Цена
Фрейм «Движение» (Motion)
Члены семьи:
Роли: Деятель,
Откуда, Куда
Фрейм «Знание» (Awareness)
Члены семьи:
Роли: Знающий
Содержание знания

Схема 3 — Подпроект 29: Роли в событии (Semantic Role Labeling)

Аналогия из делопроизводства: каждый документ имеет реквизиты — кто составил (исполнитель), кому направлен (получатель), о чём (тема), когда (дата), где (место). Разметка ролей делает то же с предложениями.

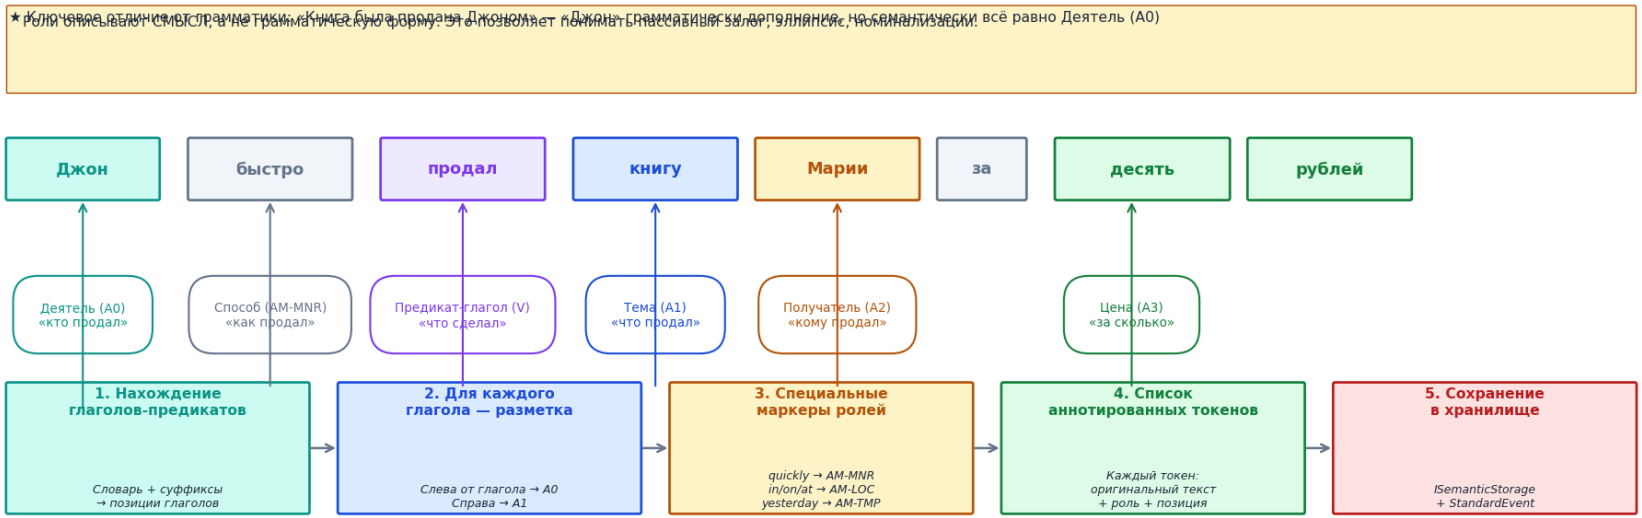


Схема 4 — Подпроект 30: Группы синонимов (WordNet)

Аналогия: тезаурус (словарь синонимов) с иерархией. «собака» → «псовые» → «млекопитающее» → «животное». WordNet — это такой тезаурус для 150 000 слов английского языка, организованный по группам одинакового значения.



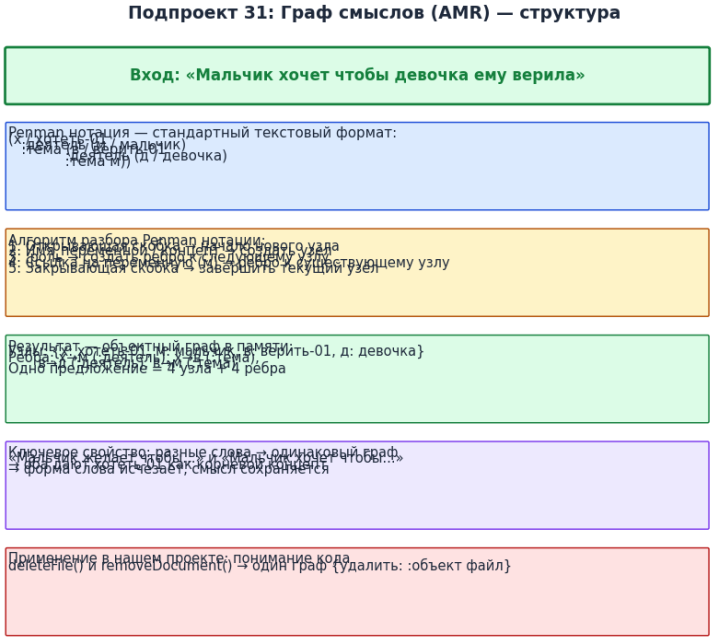


Схема 5 — Подпроект 32: Универсальные зависимости (UD)

Аналогия: организационная схема компании. Каждый сотрудник подчиняется одному руководителю (стрелка «подчиняется»). В предложении каждое слово зависит от одного главного слова. CoNLL-U формат — это таблица где каждая строка = один сотрудник (слово) с указанием руководителя (главное слово) и должности (тип зависимости).

Номер	Слово	Основа	Часть речи	Номер главного	Тип связи
1	Кот	кот	существительное	2	подлежащее
2	гнался	гнаться	глагол	0	корень предложения
3	за	за	предлог	4	предлог
4	мышью	мышь	существительное	2	косвенное дополн.

